

Final Analysis

Experiment Challenge: Credit Default Prediction

Muhammad Kholilullah | 2404220047

Prediksi Modern & Machine Learning

GitHub: <https://github.com/KholilTCM/PMML>

1 Ringkasan Data & Pendekatan

Eksperimen ini menggunakan dataset *Default of Credit Card Clients* dari UCI/Kaggle. Dataset tersebut terdiri dari 30.000 baris dan 23 prediktor setelah kolom ID dihapus, dengan target `default.payment.next.month`.

Tidak terdapat nilai yang hilang pada dataset. Ditemukan 35 baris duplikat jika ID tidak diperhitungkan. Baris tersebut tetap dipertahankan karena nasabah yang berbeda masih memungkinkan memiliki profil yang sama, dan jumlah duplikatnya juga kurang dari 0,2%. Untuk kategori **EDUCATION**, nilai 0/5/6 digabungkan ke kategori 4, sedangkan **MARRIAGE** dengan nilai 0 digabungkan ke kategori 3.

Data kemudian dibagi secara stratified menjadi 80/20, yaitu 24.000 data untuk training dan 6.000 data untuk testing, dengan `random_state=42`. Untuk preprocessing, digunakan one-hot encoding pada fitur **SEX**, **EDUCATION**, dan **MARRIAGE**, serta `StandardScaler` untuk fitur numerik. Semua proses tersebut dimasukkan ke dalam Pipeline agar tidak terjadi data leakage.

Evaluasi dilakukan menggunakan 5-fold Stratified Cross Validation pada data training. Metrik utama yang digunakan adalah F1-score (F1) untuk kelas default, sedangkan accuracy, precision, dan recall digunakan sebagai metrik pendukung.

1.1 Penanganan Imbalance

Dataset memiliki distribusi kelas yang tidak seimbang, yaitu 77,88% nasabah tidak default dan 22,12% nasabah default. Dengan kondisi tersebut, model yang selalu memprediksi “tidak default” sebenarnya sudah bisa mendapatkan accuracy sekitar 78%, tetapi tidak mampu mendeteksi nasabah yang benar-benar default.

Pada Exp 1 dan Exp 2, Test Recall masih rendah, yaitu masing-masing 0,1191 dan 0,2442, walaupun Test Accuracy cukup tinggi, yaitu 0,7945 dan 0,8088. Artinya, sekitar 76% sampai 88% nasabah yang sebenarnya default masih belum berhasil terdeteksi.

Untuk mengatasi masalah tersebut, `class_weight=balanced` kemudian diuji pada Exp 2B. Keputusan ini didasarkan pada peningkatan CV F1 dari 0,3653 menjadi 0,4811, bukan berdasarkan hasil test.

Pada Exp 2B, Test Recall meningkat menjadi 0,6307 dan Test F1 menjadi 0,4649. Namun, Test Precision turun menjadi 0,3681 dan Test Accuracy menjadi 0,6788. Penurunan tersebut merupakan trade-off yang memang terjadi setelah model lebih diarahkan untuk menangkap kelas default.

Dalam konteks kredit, gagal mendeteksi nasabah yang berpotensi default umumnya lebih berisiko dibandingkan salah menandai nasabah yang sebenarnya aman. Oleh karena itu, recall dianggap lebih penting dalam eksperimen ini.

Penggunaan `class_weight` dipertahankan secara konsisten pada Exp 3, 4, dan 5. Karena `class_weight` sudah menaikkan recall dari 0,2442 menjadi 0,6307, oversampling atau SMOTE tidak digunakan agar pipeline tetap sederhana.

2 Summary of Experiment Results

Experiment	Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
1	Logistic Regression (raw)	0,3560	0,7945	0,7117	0,1191	0,2040
2	LR + cleaning + encoding + scaling	0,3653	0,8088	0,6923	0,2442	0,3610
2B	LR + preprocessing + class_weight	0,4811	0,6788	0,3681	0,6307	0,4649
	Logistic Regression	0,4811	0,6788	0,3681	0,6307	0,4649
3	Decision Tree	0,3881	0,7273	0,3832	0,3821	0,3826
	Random Forest	0,4561	0,8152	0,6531	0,3504	0,4561
4	Tuned LR ($C = 0,01$, solver=liblinear)	0,4821	0,6815	0,3705	0,6292	0,4664
5	Gradient Boosting (HistGB)	0,5411	0,7658	0,4774	0,6202	0,5395

Baris 2B merupakan eksperimen tambahan untuk penanganan imbalance.

3 Experimental Analysis

3.1 P1. Preprocessing

Ya, terutama pada Test F1 dan recall. Dari Exp 1 ke Exp 2, CV F1 hanya naik 0,0094 (dari 0,3560 menjadi 0,3653), lebih kecil daripada CV std Exp 1 sebesar 0,0454. Namun, Test F1 naik 0,1570 (dari 0,2040 menjadi 0,3610) dan recall naik 0,1251 (dari 0,1191 menjadi 0,2442), sedangkan precision turun 0,0194 dan accuracy naik 0,0143. Meskipun begitu, recall masih rendah.

Berdasarkan CV F1, yang menjadi kriteria pemilihan model, peningkatan terbesar baru terlihat setelah penanganan imbalance pada Exp 2B, ketika CV F1 meningkat dari 0,3653 menjadi 0,4811. Peningkatan tersebut disertai penurunan pada Test Precision dan Test Accuracy.

3.2 P2. Model Comparison

Sebelum dilakukan tuning, Logistic Regression menjadi model terbaik pada Exp 3 berdasarkan CV F1 sebesar 0,4811 dan Test F1 sebesar 0,4649.

Random Forest memiliki Test Accuracy paling tinggi, yaitu 0,8152, serta Test Precision sebesar 0,6531. Namun, Test Recall-nya hanya 0,3504. Artinya, Random Forest baik dalam menghasilkan prediksi yang benar secara keseluruhan, tetapi masih melewatkan banyak nasabah default.

Decision Tree dan Random Forest menunjukkan indikasi overfitting: Train F1 masing-masing mencapai 0,9986 dan 0,9988, sedangkan CV F1 hanya 0,3881 dan 0,4561. Hal ini biasanya terjadi karena Decision Tree yang tumbuh tanpa batas kedalaman cenderung menghafal data training, dan Random Forest dengan pohon-pohon yang dalam mengalami hal serupa. Kemungkinan karena itu, Logistic Regression yang lebih sederhana menghasilkan CV F1 tertinggi.

3.3 P3. Tuning

Secara angka ya, tetapi peningkatannya sangat kecil sehingga tidak terlalu berarti secara praktis.

GridSearchCV dengan 5-fold dan scoring F1 digunakan untuk menguji 12 kombinasi dari nilai C [0,001; 0,01; 0,1; 1; 10; 100] dan solver [lbfgs; liblinear], dengan total 60 fitting. Kombinasi terbaik adalah C = 0,01 dan solver=liblinear dengan CV F1 sebesar 0,4821.

Dibandingkan sebelum tuning, CV F1 naik dari 0,4811 menjadi 0,4821 (+0,0010) dan Test F1 naik dari 0,4649 menjadi 0,4664 (+0,0015). Perubahan CV F1 tersebut jauh lebih kecil daripada CV std (sekitar 0,0115), sehingga selisihnya bisa saja hanya variasi antar fold. Logistic Regression kemungkinan sudah mendekati batas kemampuannya, sehingga tuning C tidak banyak mengubah hasil.

3.4 P4. Advanced Model

Ya, HistGradientBoosting pada Exp 5 memberikan hasil yang lebih baik dibandingkan Exp 4. CV F1 meningkat sebesar 0,0590, Test F1 meningkat 0,0731, precision meningkat 0,1069, dan accuracy meningkat 0,0843.

Di sisi lain, recall mengalami sedikit penurunan sebesar 0,0090. Jadi, terdapat trade-off kecil pada kemampuan model dalam menangkap kelas default. Secara lebih jelas, precision meningkat dari 0,3705 menjadi 0,4774, sedangkan recall hanya berubah sedikit, dari 0,6292 menjadi 0,6202.

Gradient Boosting membangun pohon secara berurutan dan tiap pohon baru memperbaiki kesalahan pohon sebelumnya, sehingga kemungkinan mampu menangkap hubungan non-linear antar fitur yang tidak bisa ditangkap Logistic Regression.

3.5 P5. Model Final

Gradient Boosting pada Exp 5 dipilih sebagai model final karena menghasilkan CV F1 sebesar 0,5411 dan Test F1 sebesar 0,5395, yang merupakan nilai tertinggi dibandingkan model-model lain yang diuji.

Nilai Train F1 sebesar 0,5628, CV F1 sebesar 0,5411, dan Test F1 sebesar 0,5395 menunjukkan bahwa model menggeneralisasi dengan baik. Selain itu, precision sebesar 0,4774 dan recall sebesar 0,6202 menunjukkan keseimbangan yang baik dalam menangani kelas default. Peningkatan CV F1 sebesar 0,0590 dibanding Exp 4 cukup besar untuk membenarkan model yang lebih kompleks.

4 Kesimpulan & Model Final

Penanganan imbalance memberikan peningkatan paling besar pada CV F1, yaitu dari 0,3653 menjadi 0,4811. Setelah itu, penggunaan Gradient Boosting kembali meningkatkan hasil, dengan CV F1 naik dari 0,4821 menjadi 0,5411 dan Test F1 dari 0,4664 menjadi 0,5395.

Sementara itu, tuning hanya memberikan peningkatan yang kecil. CV F1 berubah dari 0,4811 menjadi 0,4821, sedangkan Test F1 meningkat dari 0,4649 menjadi 0,4664.

Pada test set, model final mendeteksi 823 dari 1.327 nasabah default dan melewati 504 nasabah. Di sisi lain, 901 nasabah aman salah ditandai sebagai default. Untuk kasus kredit, kompromi ini masih masuk akal, tetapi ambang keputusan sebaiknya disesuaikan dengan biaya nyata dari kedua jenis kesalahan.

4.1 Model Final: Gradient Boosting (Exp 5)

Metrik utama:

- CV F1 = 0,5411
- Test F1 = 0,5395
- Test Precision = 0,4774
- Test Recall = 0,6202

Alasan pemilihan:

1. Memiliki CV F1 dan Test F1 tertinggi dibandingkan model yang diuji.
2. Menggeneralisasi dengan baik, dengan Train F1 0,5628, CV F1 0,5411, dan Test F1 0,5395.
3. Memiliki keseimbangan yang baik antara precision dan recall untuk kelas default.

Keterbatasan:

Evaluasi masih menggunakan satu split test set. Selain itu, Exp 5 belum dilakukan tuning, dan nilai accuracy mengalami penurunan sebagai dampak dari penggunaan `class_weight`.

Hasil Exp 1 (Logistic Regression pada data tanpa scaling) berbeda antara dua kali eksekusi notebook, sehingga angkanya dapat berbeda jika notebook dijalankan ulang. Penyebabnya belum diselidiki; dugaan awalnya adalah sensitivitas proses optimasi pada fitur yang belum di-scale. Pada dua eksekusi tersebut, hasil Exp 2 sampai Exp 5 tidak berubah.