

UTS PREDIKSI MODERN & MACHINE LEARNING

Experiment Challenge: Credit Default Prediction

A. Deskripsi UTS

Pada UTS ini, Anda akan melakukan serangkaian eksperimen *machine learning* untuk membangun model yang dapat memprediksi apakah seorang nasabah akan mengalami **default pembayaran kartu kredit** pada bulan berikutnya.

UTS ini dirancang sebagai **Experiment Challenge**. Anda tidak hanya diminta membangun satu model, tetapi melakukan beberapa eksperimen secara bertahap untuk mengetahui bagaimana **data preparation, preprocessing, pemilihan model, dan hyperparameter tuning** memengaruhi performa model.

Anda diharapkan dapat membandingkan hasil dari setiap eksperimen dan menentukan model yang paling sesuai berdasarkan hasil evaluasi.

B. Dataset

Gunakan dataset **Default of Credit Card Clients Dataset** yang tersedia pada Kaggle:

<https://www.kaggle.com/datasets/uciml/default-of-credit-card-clients-dataset>

Dataset berisi informasi mengenai karakteristik demografis, jumlah kredit, riwayat pembayaran, jumlah tagihan, dan jumlah pembayaran nasabah kartu kredit di Taiwan.

Dataset terdiri dari **30.000 observasi** dengan target berupa *binary classification*, yaitu memprediksi apakah nasabah akan mengalami *default payment* pada bulan berikutnya.

Target

Gunakan variabel:

default.payment.next.month

dengan keterangan:

- 0 = tidak mengalami default
- 1 = mengalami default

Gunakan **raw dataset** sebagaimana tersedia pada sumber tersebut.

Variabel ID **tidak digunakan sebagai predictor** dalam model.

C. Ketentuan Pengerjaan

1. Seluruh analisis dilakukan menggunakan **Python dan Google Colab**.
2. Gunakan dataset yang telah ditentukan pada bagian B.
3. Lakukan **data understanding dan data preparation** sebelum membangun model.

4. Tentukan predictor dan target dengan benar.
 5. Lakukan **train-test split** sebelum proses training model.
 6. Pastikan tidak terjadi **data leakage**.
 7. Gunakan **5-fold Cross Validation** pada proses evaluasi model dan hyperparameter tuning.
 8. Gunakan **F1-score sebagai metrik utama**.
 9. Gunakan **Accuracy, Precision, dan Recall** sebagai metrik pendukung.
 10. Dokumentasikan seluruh proses dan hasil eksperimen pada notebook.
 11. Anda diperbolehkan menggunakan library machine learning yang relevan, seperti scikit-learn, xgboost, dan library lain yang diperlukan.
 12. Setiap keputusan preprocessing atau pemodelan harus dapat dijelaskan berdasarkan hasil eksperimen.
-

D. EXPERIMENT CHALLENGE

Lakukan eksperimen berikut secara berurutan.

Experiment 0 — Data Understanding & Preparation

Sebelum membangun model, lakukan eksplorasi dan persiapan data.

Minimal lakukan:

- membaca dataset;
- melihat dimensi dataset;
- melihat struktur dan tipe data;
- mengidentifikasi variabel target;
- memeriksa missing value;
- memeriksa duplicate;
- memeriksa nilai yang tidak sesuai atau tidak wajar;
- melihat distribusi variabel target;
- menentukan predictor dan target;
- mengeluarkan variabel ID dari predictor;
- melakukan train-test split;
- melakukan preprocessing yang diperlukan.

Tampilkan dan jelaskan secara singkat hasil pemeriksaan data serta keputusan preprocessing yang Anda lakukan.

Catatan: Tidak semua teknik preprocessing harus digunakan. Terapkan hanya preprocessing yang relevan berdasarkan kondisi dataset.

Experiment 1 — Baseline Model

Bangun **Logistic Regression** sebagai *baseline model*.

Lakukan evaluasi menggunakan:

- **5-fold Cross Validation** pada training set;
- evaluasi pada test set.

Laporkan:

- Accuracy
- Precision
- Recall
- F1-score
- CV F1-score

Hasil Experiment 1 akan menjadi **baseline** yang digunakan untuk membandingkan eksperimen berikutnya.

Experiment 2 — Preprocessing

Lakukan preprocessing yang sesuai terhadap data dan bangun kembali model Logistic Regression.

Anda dapat mempertimbangkan teknik seperti:

- feature scaling;
- encoding;
- atau preprocessing lain yang relevan.

Bandingkan hasil Experiment 2 dengan baseline pada Experiment 1.

Tentukan:

Apakah preprocessing yang dilakukan memberikan peningkatan performa model?

Gunakan hasil evaluasi untuk mendukung jawaban Anda.

Experiment 3 — Model Comparison

Bangun dan evaluasi minimal **tiga model machine learning** berikut:

1. Logistic Regression
2. Decision Tree
3. Random Forest

Gunakan prosedur evaluasi yang sama untuk setiap model.

Bandingkan model berdasarkan:

- CV F1-score;
- Test Accuracy;
- Test Precision;
- Test Recall;
- Test F1-score.

Berdasarkan hasil eksperimen, tentukan **model terbaik** yang akan digunakan pada Experiment 4.

Model terbaik ditentukan berdasarkan hasil evaluasi, bukan berdasarkan asumsi bahwa model tertentu pasti lebih baik.

Experiment 4 — Hyperparameter Tuning

Gunakan model terbaik dari Experiment 3.

Lakukan **hyperparameter tuning menggunakan GridSearchCV dengan 5-fold Cross Validation**.

Tentukan beberapa hyperparameter yang relevan untuk model yang digunakan.

Laporkan:

- hyperparameter yang diuji;
- kombinasi hyperparameter terbaik;
- best CV F1-score;
- Test Accuracy;
- Test Precision;
- Test Recall;
- Test F1-score.

Kemudian bandingkan performa model:

sebelum tuning vs setelah tuning.

Tentukan apakah hyperparameter tuning memberikan peningkatan performa.

Experiment 5 — Advanced Model

Gunakan minimal **satu metode machine learning yang lebih advanced**.

Anda dapat memilih salah satu metode berikut:

- Gradient Boosting;
- AdaBoost;
- XGBoost;
- Stacking;
- atau metode ensemble/boosting lain yang relevan.

Lakukan training dan evaluasi model menggunakan prosedur yang sesuai.

Laporkan:

- CV F1-score;
- Test Accuracy;
- Test Precision;
- Test Recall;
- Test F1-score.

Kemudian bandingkan hasil model advanced dengan model terbaik dari Experiment 4.

Catatan: Model yang lebih kompleks tidak selalu menghasilkan performa yang lebih baik. Kesimpulan harus didasarkan pada hasil eksperimen.

E. FINAL ANALYSIS

Setelah menyelesaikan seluruh eksperimen, buat **PDF Final Analysis** yang berisi ringkasan hasil dan interpretasi dari seluruh eksperimen.

1. Summary of Experiment Results

Buat satu tabel yang merangkum hasil eksperimen:

Experiment	Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
1	Baseline					
2	Baseline + Preprocessing					
3	Model Comparison					
4	Tuned Model					
5	Advanced Model					

Pastikan seluruh nilai pada tabel sesuai dengan hasil yang terdapat pada notebook.

2. Experimental Analysis

Berdasarkan hasil eksperimen, jawab pertanyaan berikut secara singkat dan jelas.

Pertanyaan 1 — Preprocessing

Apakah preprocessing pada Experiment 2 memberikan peningkatan performa dibandingkan dengan baseline?

Jelaskan berdasarkan perubahan nilai F1-score dan metrik lainnya.

Pertanyaan 2 — Model Comparison

Model apa yang memberikan performa terbaik pada Experiment 3 sebelum dilakukan hyperparameter tuning?

Jelaskan berdasarkan hasil Cross Validation dan test set.

Pertanyaan 3 — Hyperparameter Tuning

Apakah hyperparameter tuning pada Experiment 4 meningkatkan performa model?

Bandingkan performa model sebelum dan sesudah tuning.

Pertanyaan 4 — Advanced Model

Apakah model advanced pada Experiment 5 memberikan performa yang lebih baik dibandingkan model terbaik dari eksperimen sebelumnya?

Jelaskan berdasarkan hasil evaluasi.

Pertanyaan 5 — Final Model

Berdasarkan seluruh eksperimen, model mana yang Anda pilih sebagai model final?

Jelaskan alasan pemilihan model tersebut berdasarkan hasil eksperimen.

Catatan: Model final tidak harus merupakan model yang paling kompleks. Pemilihan model harus didasarkan pada hasil evaluasi dan alasan yang didukung oleh hasil eksperimen.

F. FORMAT PENGUMPULAN

Setiap mahasiswa wajib mengumpulkan **dua output**:

1. GitHub Repository

Seluruh proses pengerjaan dilakukan menggunakan **Google Colab**.

Setelah selesai, notebook Google Colab harus diunggah ke **GitHub Repository**.

Repository harus berisi notebook (.ipynb) yang memuat:

- Data Understanding;
- Data Preparation;
- Experiment 1;
- Experiment 2;
- Experiment 3;
- Experiment 4;
- Experiment 5;
- seluruh kode;
- output hasil eksperimen;
- hasil evaluasi setiap model;
- hasil hyperparameter tuning.

Yang dikumpulkan:

Link GitHub Repository

Bukan link Google Colab.

Pastikan repository dapat diakses oleh dosen.

2. PDF Final Analysis

Kumpulkan **1 file PDF** yang berisi:

- tabel ringkasan hasil seluruh eksperimen;
- jawaban 5 pertanyaan analisis;
- kesimpulan;
- model final yang dipilih;
- alasan pemilihan model final.

Tidak perlu menyalin seluruh kode ke dalam PDF.

Kode dan output eksperimen disimpan pada notebook yang terdapat di GitHub Repository.

G. SUBMISSION CHECKLIST

Sebelum mengumpulkan, pastikan:

- ☐ Dataset yang digunakan sesuai dengan dataset yang ditentukan.
- ☐ Notebook Google Colab telah diunggah ke GitHub.
- ☐ GitHub Repository dapat diakses oleh dosen.
- ☐ PDF Final Analysis telah dibuat.
- ☐ Hasil pada PDF sesuai dengan hasil pada notebook.

Yang dikumpulkan:

1. Link GitHub Repository

2. PDF Final Analysis

Kumpulkan pada link berikut:

[Link Pengumpulan UTS Machine Learning](#)